RELATÓRIO TÉCNICO DE DESENVOLVIMENTO E VALIDAÇÃO DO MODELO DE IA

Corpus Base: Fake.br Corpus

Artefatos Vinculados: `avaliacao_modelo_fakebr.ipynb` | `modelo_classificador_fakebr.pkl`

1. Processo de Preparação dos Dados e Treinamento

1.1. Consolidação e Caracterização do Corpus

O desenvolvimento utilizou o subconjunto `size_normalized_texts` do Fake.br Corpus, totalizando **1.821 notícias jornalísticas**, distribuídas em **1.000 notícias falsas (54,91%)** e **821 verdadeiras (45,09%)**.

A escolha desse subconjunto específico garantiu que textos falsos e verdadeiros apresentassem extensões equivalentes em média (aproximadamente 178 palavras e 1.075 caracteres), eliminando a hipótese de o classificador usar o tamanho do texto ou contagem superficial de tokens como atalho trivial de predição.

1.2. Prevenção Estrita de Vazamento de Dados (*Data Leakage*)

Para garantir a integridade estatística da avaliação, o corpus foi submetido inicialmente a uma divisão estratificada em **70% para treinamento** e **30% para teste** (`random_state=42`).

O conjunto de teste preservado contou com **547 amostras independentes** (247 verdadeiras e 300 falsas), sendo completamente isolado do fluxo de engenharia de atributos, agrupamento e reamostragem.

1.3. Mitigação de Dependência Temática (*Topic Bias*) via MiniBatchKMeans

A Análise Exploratória de Dados (EDA) evidenciou que notícias falsas no dataset estavam concentradas em temas específicos (e.g., operações policiais e figuras políticas polarizadas). Uma subamostragem aleatória convencional faria o modelo associar o *assunto* à falsidade (*topic bias*).

Para solucionar o problema:

1. Os 1.274 textos do conjunto de treino foram vetorizados via TF-IDF (`min_df=3` , 50.000 features) e segmentados em **30 clusters temáticos** através do algoritmo **`MiniBatchKMeans`** (`batch_size=1024`).
2. Foram mantidos integralmente todos os **574 textos verdadeiros** do treino.
3. Aplicou-se subamostragem controlada por cotas nas notícias falsas dentro de cada cluster, descartando 126 notícias falsas excedentes de maneira uniforme entre os tópicos.
4. O conjunto de treino final foi balanceado com **paridade global perfeita de 1.148 notícias (574 verdadeiras e 574 falsas)**, preservando a diversidade semântica do corpus.

2. Critérios de Seleção da Abordagem e Comparação de Modelos

Optou-se pela arquitetura composta por **Vetorização TF-IDF (unigramas e bigramas) + Regressão Logística com Calibração de Platt via Sigmoide**. A decisão foi fundamentada em compensações (*trade-offs*) técnicas, latência e explicabilidade:

2.1. Por que a Regressão Logística Calibrada?

- **Interpretabilidade e Estilometria:** A representação linear permite extrair e auditar os coeficientes léxicos associados a cada classe. O modelo identificou padrões formais e apelativos (estilo de escrita) em vez de atuar como um mero memorizador de tópicos contextuais.
- **Baixa Latência para Consumo em Tempo Real:** Sendo uma aplicação consumida por extensão de navegador em tempo real, a inferência precisa ocorrer em menos de 15 ms, sem requerer aceleradores gráficos (GPUs) ou infraestrutura computacional pesada.
- **Calibração de Probabilidades Realistas (Platt Scaling):** Classificadores binários tradicionais produzem escores extremos (sobreconfiança). O invólucro `CalibratedClassifierCV(method='sigmoid', cv=5)` mapeia a distância ao hiperplano em probabilidades a posteriori confiáveis.

- **Mecanismo Ético de Abstenção (`INCERTO`):** Em tarefas críticas como combate à desinformação, forçar uma decisão quando o modelo está incerto acarreta danos à credibilidade do produto. As probabilidades calibradas permitiram fixar uma margem de dúvida (limiar de 65%). Se a probabilidade da classe dominante for inferior a esse limiar, o modelo assume o estado **INCERTO**, abstendo-se de emitir vereditos levianos.

2.2. Por que outras abordagens foram descartadas?

- **Naive Bayes (MultinomialNB):** Embora eficiente e leve, o algoritmo assume premissa de independência condicional entre palavras, desconsiderando a coocorrência sintática de bigramas críticos. Além disso, tende a calibrar muito mal as probabilidades nas extremidades (0% ou 100%), impossibilitando a política de abstenção.
- **Random Forest e Árvores de Decisão:** Em espaços vetoriais esparsos e de alta dimensionalidade (vetores TF-IDF de até 150.000 features), árvores de decisão criam partições subótimas e sofrem de alta variância. Conjuntos em árvore (*Random Forest*) aumentam expressivamente o tempo de inferência e geram arquivos serializados excessivamente pesados (centenas de megabytes), sem ganhos significativos de desempenho em texto puro.
- **Modelos de Linguagem Profundos / Transformers (BERT/LLMs como Classificador Factual):** O uso de modelos pré-treinados profundos para classificação direta foi rejeitado por três razões: (1) risco aumentado de viés de tópico (*topic bias*) devido ao conhecimento prévio do modelo pré-treinado; (2) peso do artefato e tempo de resposta incompatíveis com a borda; e (3) premissa de arquitetura que reservou LLMs locais (Ollama `llama3.2:1b`) exclusivamente para síntese neutra e descritiva, e não para julgar a veracidade do fato.

3. Métricas de Desempenho e Análise dos Resultados

A avaliação no conjunto de teste independente (547 notícias não vistas) apresentou métricas consistentes e equilibradas entre as classes:

3.1. Relatório de Classificação no Teste

Classe	Precisão	Recall (Revocação)	F1-Score	Suporte (Amostras)
Verdadeira (0)	0,91	0,91	0,91	247
Falsa (1)	0,93	0,93	0,93	300

Acurácia Geral	—	—	**91,96%**	547
Macro Avg	0,92	0,92	0,92	547
Weighted Avg	0,92	0,92	0,92	547

- **F1-Score Macro: 0,9188**
- **Acurácia Global: 91,96%**

3.2. Matriz de Confusão

$$\begin{bmatrix} 225 & 22 \\ 22 & 278 \end{bmatrix}$$

- **Verdadeiros Negativos (Verdadeiras corretas):** 225 amostras.
- **Verdadeiros Positivos (Falsas corretas):** 278 amostras.
- **Falsos Positivos (Verdadeiras taxadas como falsas):** 22 amostras (baixa taxa de erro: 8,9%).
- **Falsos Negativos (Falsas taxadas como verdadeiras):** 22 amostras (baixa taxa de erro: 7,3%).

A simetria na matriz de confusão demonstra que a estratégia de balanceamento temático e os pesos de classe balanceados impediram o algoritmo de privilegiar qualquer uma das vertentes.

4. Principais Desafios Enfrentados

1. **Risco de Correlações Espúrias ("Detector de Calendário"):** A auditoria dos dados revelou forte presença de datas e dias da semana (*"nesta terça-feira"*, *"quarta-feira"*) associados a notícias verdadeiras pela formalidade jornalística, enquanto matérias falsas abusavam de termos alarmistas (*"urgente"*, *"veja"*). O balanceamento impediu que o modelo se degenerasse em um mero detector de datas.
2. **Polarização e Entidades Nomeadas:** Sem agrupamento semântico, certas figuras públicas e operações judiciais concentravam rótulos desbalanceados no Fake.br Corpus. O balanceamento via clusters temáticos do KMeans mitigou o viés associativo entre nomes e credibilidade.
3. **Calibração e Confiabilidade na Borda:** Assegurar que os limiares de probabilidade refletissem incerteza estatística genuína, possibilitando o funcionamento íntegro da política de abstenção ética.

5. Aprendizados e Lições Adquiridas

- **A Qualidade da Preparação Supera a Complexidade Algorítmica:** O esforço metodológico de auditoria, isolamento de teste e subamostragem por clusters gerou ganhos de robustez superiores aos que seriam obtidos adicionando complexidade não-linear ao classificador.
- **A Ética da Abstenção na IA:** Reconhecer quando o modelo não possui evidências textuais suficientes (`INCERTO`) é um avanço metodológico fundamental para ferramentas públicas de checagem, prevenindo conclusões precipitadas sobre desinformação.
- **Classificação Estilométrica vs. Ontologia Factual:** O modelo supervisionado atua como um sinalizador probabilístico do estilo da escrita (padrões de formalidade e retórica), e não como detentor da verdade universal do fato.